## Floating point Half-precision

Lo standard half-precision segue le stesse regole dello standard IEEE 754, utilizzando però la metà dei bit, cioè 16. Se ne utilizza sempre uno per il segno, 5 per l'esponente e i 10 restanti per la mantissa. All'esponente verrà sottratto 14.

$$\pm 1$$
,  $M \times 2^{E-14}$ 

M = 10 bit E = 5 bit Segno = 1 bit

Il numero più piccolo denormalizzato rappresentabile è  $2^{-24}$  cioè  $5,96\times10^{-8}$  Che sarebbe in binario 0000000000000001 Il numero più grande è 65504 cioè 000001000000000

## Floating point Double-precision

Lo standard double-precision segue le stesse regole dello standard IEEE 754, utilizzando però il doppio dei bit, cioè 64. Se ne utilizza sempre uno per il segno, 11 per l'esponente e i 52 restanti per la mantissa. All'esponente verrà sottratto 1023.

## Addizione tra 2 floating point

Per eseguire l'addizione fra 2 numeri floating point vanno seguiti vari step, prendiamo per esempio i 2 numeri :

0x3FC00000 0x40500000

1) Prima di tutto estraiamo la mantissa e l'esponente

- 2) Ora che abbiamo le cifre decimali procediamo alla somma

$$1,5+3,25 = 4,75$$

3) Possiamo anche fare la somma direttamente in binario

Per sommare 2 numeri devo prima portare gli esponenti allo stesso valore

SHIFTO la virgola del numero con l'esponente minore verso sinistra, ed aggiungo un unità all'esponente

Adesso eseguo la somma

10,011 \* 2^1 equivale a 2,375 \* 2 cioè 4,75

Normalizzo la mantissa spostando la virgola verso sinistra ed aggiungendo un unità all'esponente

1,0011 \* 2^2in floating point è:

si ricordi di sommare 127 all'esponente

0x40980000

## Moltiplicazione tra 2 floating point

Prendiamo come esempio sempre i due numeri 1,5 \* 2^0 e 1,375 \* 2^1

Trasformiamo i 2 valori in binario, moltiplichiamoli trascurando gli esponenti, il risultato avrà come esponente quello maggiore.

Moltiplicazione in colonna:

1) Come primo step eseguiamo la moltiplicazione fra i 2 numeri trascurando la virgola :

```
001100 *
001011 =

001100 +
011000 +
000000 +
1100000 =
```

2)Adesso del numero 10000100 bisogna capire dove mettere la virgola, per capirlo bisogna sommare la cardinalità dei numeri dopo la virgola dei valori iniziali.

 $1,100 = \frac{3}{3}$  numeri dopo la virgola  $1,011 = \frac{3}{3}$  numeri dopo la virgola

3 + 3 = 6 La virgola verrà spostata di 6 posizioni a partire dal primo numero a destra

10,000100

Il risultato della moltiplicazione sarà quindi 10,011100 \* 2^1. Normalizziamo il valore rendendo la parte intera della mantissa uguale ad 1:

10,000100 \* 2^1 = 1,0000100 \* 2^2

Il nostro risultato è 1,0000100 \* 2^2, trasformiamolo in IEEE 754 adesso :

esadecimale: 0x40940000